

PROJET 2

Data Analyst

2025 - 2026

Jean Paul MALAN

Guy Roger Junior GNAORE

COULIBALY Fobeh

TOURE Awa

GROUPE 6

Prediction de la

Consommation Energetique

Dashboard interactif | 6 modeles ML | SHAP | Anomalies | Clustering

Dataset : UCI Appliances Energy Prediction | 19 735 obs. | 10 min

Contexte & Problematique

Pourquoi predire la consommation electrique ?

Enjeu energetique

La consommation residentielle represente 30 % de l'energie mondiale.

Optimiser l'usage permet des economies significatives et reduit l'empreinte carbone.

Objectif du projet

Construire un modele ML capable de predire la consommation (Wh) des appareils

electriques a partir de capteurs internes et de donnees meteorologiques.

Approche adoptee

Feature engineering avance, 6 modeles compares, validation croisee temporelle,

interpretabilite SHAP et dashboard interactif Streamlit deploye en ligne.

Dataset UCI Appliances Energy Prediction

Maison en Belgique | Janv. - Mai 2016 | Frequence 10 minutes

19 735

Observations

26

Variables explicatives

10 min

Frequence de mesure

97.7 Wh

Consommation moyenne

10 - 1080

Plage cible (Wh)

5 mois

Periode couverte

Methodologie — Pipeline ML

De la donnee brute a la prediction

1

Chargement & nettoyage

Lecture CSV, suppression rv1/rv2/lights, tri chronologique

2

Feature Engineering

Lags H-1/H-2/H-6/J-1/J-7, rolling 6h/24h, encodage cyclique heure/jour/mois

3

Split chronologique 80/20

Train : Jan - Avr 2016 | Test : Avr - Mai 2016

4

Entrainement 6 modeles

Lin. Reg., Ridge, Lasso, SVR, Random Forest, Gradient Boosting

5

Evaluation & SHAP

R^2 , RMSE, MAE, MAPE + validation croisee TimeSeriesSplit 5 folds

Les 6 modeles compares



Regression Lineaire



Ridge (L2) — alpha=100



Lasso (L1) — alpha=0.1



SVR — RBF, C=100



Random Forest — 100 arbres, depth=12



Gradient Boosting — 300 est., lr=0.1

Resultats — Comparaison des 6 modeles

Jeu de test chronologique (20 % des donnees — Avr./Mai 2016)

Modele	R²	RMSE (Wh)
Ridge (L2)	0.548	65.3
Gradient Boosting	0.531	66.8
Random Forest	0.524	67.4
Lasso (L1)	0.521	67.7
SVR	0.498	69.1
Regression Lineaire	0.482	70.1

Meilleur modele

Ridge (L2)

R² = 0.548


Un R² de 0.54 est conforme a la
litterature scientifique sur ce dataset.
La consommation depend du comportement
humain — bruit irreductible par definition.

RMSE = 65.3 Wh | MAE = 43.1 Wh


Validation Croisee Temporelle — TimeSeriesSplit

5 folds chronologiques : entrainer sur le passe, tester sur le futur

Principe



R² moyen par modele (5 folds)



Interpretabilite — Analyse SHAP

SHapley Additive exPlanations : contribution de chaque variable a la prediction

Principe SHAP


Chaque valeur SHAP mesure la contribution d'une variable a une prediction individuelle.

SHAP > 0 => augmente la prediction

SHAP < 0 => diminue la prediction

Calcule sur 500 observations du jeu de test avec TreeExplainer (modeles arborescents).

Top 8 variables les plus influentes



Detection d'Anomalies & Clustering

Analyse exploratoire de la consommation

Detection d'Anomalies — Seuil 2-sigma	
Methode	Residus > 2 ecarts-types ($ e > 2 \cdot \sigma$)
Seuil par default	Ajustable via slider (1.5 a 3.0)
Taux detecete	~5 a 8 % des observations
Interpretation	Pics inattendus ou chutes brusques
Utilite	Detection pannes, comportements atypiques

Clustering K-Means — Profils journaliers	
	Cluster 1 Consommation faible & stable (nuits, absences)
	Cluster 2 Matinee active — pic au lever
	Cluster 3 Soiree intense — peak 18h-22h
	Cluster 4 Weekend — profil etale sur la journee

Dashboard Interactif — Streamlit

8 onglets | Deploye en ligne | Rapport PDF integre

Temporel

Serie temporelle, profils horaires/hebdo, heatmap

Anomalies

Detection 2-sigma, carte des anomalies, statistiques

Modeles

Comparaison 6 modeles, SHAP, validation croisee, radar

Rapport PDF

Generation PDF 8 pages en 1 clic, telechargeable

Predictions

Predictions vs reel, residus, scatter interactif

Clustering

K-Means 4 profils journaliers, radar, scatter

Simulateur

Prediction instantanee, gauge, comparaison 5 modeles

Contexte Senelec

Donnees Senelec 2022-2024, mix energetique, tendances

Conclusion & Perspectives

Acquis

 $R^2 = 0.548$ (Ridge) — conforme littérature

 6 modeles ML compares objectivement

 Validation croisee TimeSeriesSplit

 SHAP : variables lag les + influentes

 Dashboard Streamlit deploye en ligne

 Detection anomalies automatique

Limites

 Dataset ancienne (2016, Belgique)

 Comportement humain = bruit irreductible

 Pas de donnees temps reel

 SVR lent sur grands datasets

Perspectives

 LSTM / modeles sequentiels (deep learning)

 Donnees Senelec temps reel

 Re-entrainement mensuel automatise

 Optimisation hyperparametres (GridSearch)

 Extension a d'autres batiments